

Individual papers

Observed exact-rank
(Spearman ρ)

GPT-5 Mini	1.00	0.40	0.37	0.45	0.31
GPT-5 Nano	0.40	1.00	0.36	0.36	0.26
GPT-4.1	0.37	0.36	1.00	0.46	0.26
GPT-4.1 Mini	0.45	0.36	0.46	1.00	0.30
GPT-5.1	0.31	0.26	0.26	0.30	1.00
	GPT-5 Mini	GPT-5 Nano	GPT-4.1	GPT-4.1 Mini	GPT-5.1

Repeat-based rank
ceiling (avg-5)

GPT-5 Mini	1.00	0.68	0.73	0.73	0.65
GPT-5 Nano	0.68	1.00	0.71	0.70	0.62
GPT-4.1	0.73	0.71	1.00	0.76	0.67
GPT-4.1 Mini	0.73	0.70	0.76	1.00	0.67
GPT-5.1	0.65	0.62	0.67	0.67	1.00
	GPT-5 Mini	GPT-5 Nano	GPT-4.1	GPT-4.1 Mini	GPT-5.1

Collections

Observed exact-rank
(Spearman ρ)

GPT-5 Mini	1.00	0.29	0.45	0.41	0.47
GPT-5 Nano	0.29	1.00	0.40	0.42	0.34
GPT-4.1	0.45	0.40	1.00	0.64	0.44
GPT-4.1 Mini	0.41	0.42	0.64	1.00	0.44
GPT-5.1	0.47	0.34	0.44	0.44	1.00
	GPT-5 Mini	GPT-5 Nano	GPT-4.1	GPT-4.1 Mini	GPT-5.1

Repeat-based rank
ceiling (avg-5)

GPT-5 Mini	1.00	0.63	0.79	0.76	0.73
GPT-5 Nano	0.63	1.00	0.70	0.68	0.65
GPT-4.1	0.79	0.70	1.00	0.85	0.82
GPT-4.1 Mini	0.76	0.68	0.85	1.00	0.78
GPT-5.1	0.73	0.65	0.82	0.78	1.00
	GPT-5 Mini	GPT-5 Nano	GPT-4.1	GPT-4.1 Mini	GPT-5.1

Repeat ceiling uses within-model repeat-to-repeat ranking agreement, projected to the 5-repeat aggregate via a Spearman-Brown correction.