

Individual papers

Spearman rho

GPT-5.1	1.00	0.30	0.26	0.26	0.31	0.22	0.27
GPT-4.1 Mini	0.30	1.00	0.46	0.36	0.45	0.22	0.32
GPT-4.1	0.26	0.46	1.00	0.36	0.38	0.20	0.22
GPT-5 Nano	0.26	0.36	0.36	1.00	0.40	0.15	0.18
GPT-5 Mini	0.31	0.45	0.38	0.40	1.00	0.22	0.35
Claude Sonnet 4.6	0.22	0.22	0.20	0.15	0.22	1.00	0.23
Gemini 2.5 Pro	0.27	0.32	0.22	0.18	0.35	0.23	1.00

GPT-5.1
GPT-4.1 Mini
GPT-4.1
GPT-5 Nano
GPT-5 Mini
Claude Sonnet 4.6
Gemini 2.5 Pro

Order agreement
(excluding near-ties)

GPT-5.1	1.00	0.80	0.80	0.76	0.79	0.85	0.73
GPT-4.1 Mini	0.80	1.00	0.94	0.88	0.91	0.82	0.78
GPT-4.1	0.80	0.94	1.00	0.88	0.91	0.88	0.74
GPT-5 Nano	0.76	0.88	0.88	1.00	0.89	0.80	0.70
GPT-5 Mini	0.79	0.91	0.91	0.89	1.00	0.87	0.80
Claude Sonnet 4.6	0.85	0.82	0.88	0.80	0.87	1.00	0.81
Gemini 2.5 Pro	0.73	0.78	0.74	0.70	0.80	0.81	1.00

GPT-5.1
GPT-4.1 Mini
GPT-4.1
GPT-5 Nano
GPT-5 Mini
Claude Sonnet 4.6
Gemini 2.5 Pro

Spearman rho

GPT-5.1	1.00	0.44	0.44	0.34	0.47	0.40	0.38
GPT-4.1 Mini	0.44	1.00	0.64	0.43	0.41	0.48	0.19
GPT-4.1	0.44	0.64	1.00	0.40	0.45	0.51	0.29
GPT-5 Nano	0.34	0.43	0.40	1.00	0.29	0.37	0.16
GPT-5 Mini	0.47	0.41	0.45	0.29	1.00	0.40	0.37
Claude Sonnet 4.6	0.40	0.48	0.51	0.37	0.40	1.00	0.39
Gemini 2.5 Pro	0.38	0.19	0.29	0.16	0.37	0.39	1.00

GPT-5.1
GPT-4.1 Mini
GPT-4.1
GPT-5 Nano
GPT-5 Mini
Claude Sonnet 4.6
Gemini 2.5 Pro

Order agreement
(excluding near-ties)

GPT-5.1	1.00	0.87	0.87	0.82	0.91	0.92	0.79
GPT-4.1 Mini	0.87	1.00	0.96	0.88	0.89	0.96	0.69
GPT-4.1	0.87	0.96	1.00	0.90	0.93	0.96	0.76
GPT-5 Nano	0.82	0.88	0.90	1.00	0.87	0.90	0.69
GPT-5 Mini	0.91	0.89	0.93	0.87	1.00	0.94	0.84
Claude Sonnet 4.6	0.92	0.96	0.96	0.90	0.94	1.00	0.89
Gemini 2.5 Pro	0.79	0.69	0.76	0.69	0.84	0.89	1.00

GPT-5.1
GPT-4.1 Mini
GPT-4.1
GPT-5 Nano
GPT-5 Mini
Claude Sonnet 4.6
Gemini 2.5 Pro

epsilon = 0.06. Order agreement excludes item pairs whose score gap is at most epsilon in either model.