

Individual papers

Spearman ρ

GPT-5.1	1.00	0.24	0.26	0.22	0.31
GPT-4.1 Mini	0.24	1.00	0.44	0.37	0.42
GPT-4.1	0.26	0.44	1.00	0.35	0.36
GPT-5 Nano	0.22	0.37	0.35	1.00	0.39
GPT-5 Mini	0.31	0.42	0.36	0.39	1.00
	GPT-5.1	GPT-4.1 Mini	GPT-4.1	GPT-5 Nano	GPT-5 Mini

Order agreement
(excluding near-ties)

GPT-5.1	1.00	0.74	0.80	0.72	0.80
GPT-4.1 Mini	0.74	1.00	0.93	0.88	0.89
GPT-4.1	0.80	0.93	1.00	0.89	0.91
GPT-5 Nano	0.72	0.88	0.89	1.00	0.89
GPT-5 Mini	0.80	0.89	0.91	0.89	1.00
	GPT-5.1	GPT-4.1 Mini	GPT-4.1	GPT-5 Nano	GPT-5 Mini

Collections

Spearman ρ

GPT-5.1	1.00	0.44	0.45	0.37	0.46
GPT-4.1 Mini	0.44	1.00	0.63	0.38	0.42
GPT-4.1	0.45	0.63	1.00	0.36	0.45
GPT-5 Nano	0.37	0.38	0.36	1.00	0.29
GPT-5 Mini	0.46	0.42	0.45	0.29	1.00
	GPT-5.1	GPT-4.1 Mini	GPT-4.1	GPT-5 Nano	GPT-5 Mini

Order agreement
(excluding near-ties)

GPT-5.1	1.00	0.88	0.89	0.85	0.92
GPT-4.1 Mini	0.88	1.00	0.96	0.86	0.90
GPT-4.1	0.89	0.96	1.00	0.88	0.94
GPT-5 Nano	0.85	0.86	0.88	1.00	0.88
GPT-5 Mini	0.92	0.90	0.94	0.88	1.00
	GPT-5.1	GPT-4.1 Mini	GPT-4.1	GPT-5 Nano	GPT-5 Mini

$\varepsilon = 0.06$. Order agreement excludes item pairs whose score gap is at most ε in either model; the left panel remains exact Spearman ρ .